

Оленева Валентина, ИУ5-25МВ, ММО АСОИУ, Рубежный контроль №1

Задача №5.

Для набора данных проведите кодирование одного (произвольного) категориального признака с использованием метода "one-hot encoding".

1. Установка и импорт библиотек

```
!pip install seaborn matplotlib pandas --quiet

import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
```

2. Загрузка набора данных

```
# Используем встроенный датасет penguins
df = sns.load_dataset('penguins')
print("Первые 5 строк данных:")
print(df.head())
print("\nИнформация о данных:")
print(df.info())
```

3. Предварительная обработка (удаление пропусков)

```
# Для pairplot и one-hot encoding избавимся от строк с NaN
df_clean = df.dropna()
print(f"\nРазмер после удаления пропусков: {df_clean.shape}")
```

4. Построение парных диаграмм (pairplot)

```
# Выбираем числовые колонки для pairplot
numerical_cols = df_clean.select_dtypes(include=[np.number]).columns.tolist()
print(f"\nЧисловые признаки для pairplot: {numerical_cols}")

# Строим парные диаграммы с цветовой дифференциацией по виду пингвина (опционально)
sns.pairplot(df_clean, vars=numerical_cols, hue='species', diag_kind='kde')
plt.suptitle('Парные диаграммы числовых признаков', y=1.02)
plt.show()
```

5. One-hot encoding для категориального признака

```
# Выбираем произвольный категориальный признак – 'island' (остров обитания)
categorical_feature = 'island'
print(f"\nВыбран категориальный признак: '{categorical_feature}'")
print("Уникальные значения:", df_clean[categorical_feature].unique())
```

```

# Применяем one-hot encoding с помощью pandas get_dummies
one_hot_encoded = pd.get_dummies(df_clean[categorical_feature], prefix=categorical_feature)

# Добавляем закодированные столбцы к исходному DataFrame
df_final = pd.concat([df_clean, one_hot_encoded], axis=1)

# Можно удалить исходный категориальный столбец (по желанию)
# df_final.drop(categorical_feature, axis=1, inplace=True)

print("\nРезультат one-hot encoding:")
print(f"Добавлены столбцы: {one_hot_encoded.columns.tolist()}")
print("\nПервые 5 строк после кодирования:")
print(df_final.head())

```

6. Проверка (демонстрация изменений)

```

print("\nИтоговая размерность DataFrame:", df_final.shape)
print("Типы данных после one-hot encoding:")
print(df_final.dtypes)

```

```

Выбран категориальный признак: 'island'
Уникальные значения: ['Torgersen' 'Biscoe' 'Dream']

Результат one-hot encoding:
Добавлены столбцы: ['island_Biscoe', 'island_Dream', 'island_Torgersen']

Первые 5 строк после кодирования:

```

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm \
0	Adelie	Torgersen	39.1	18.7	181.0
1	Adelie	Torgersen	39.5	17.4	186.0
2	Adelie	Torgersen	40.3	18.0	195.0
4	Adelie	Torgersen	36.7	19.3	193.0
5	Adelie	Torgersen	39.3	20.6	190.0

	body_mass_g	sex	island_Biscoe	island_Dream	island_Torgersen
0	3750.0	Male	False	False	True
1	3800.0	Female	False	False	True
2	3250.0	Female	False	False	True
4	3450.0	Female	False	False	True
5	3650.0	Male	False	False	True


```

Итоговая размерность DataFrame: (333, 10)
Типы данных после one-hot encoding:
species          object
island           object
bill_length_mm   float64
bill_depth_mm    float64
flipper_length_mm float64
body_mass_g      float64
sex              object
island_Biscoe    bool
island_Dream     bool
island_Torgersen bool
dtype: object

```

Доп. Задание:

Для произвольной колонки данных построить парные диаграммы (pairplot).

Первые 5 строк данных:

```
species  island  bill_length_mm  bill_depth_mm  flipper_length_mm  \
0  Adelie  Torgersen           39.1           18.7           181.0
1  Adelie  Torgersen           39.5           17.4           186.0
2  Adelie  Torgersen           40.3           18.0           195.0
3  Adelie  Torgersen           NaN           NaN           NaN
4  Adelie  Torgersen           36.7           19.3           193.0

body_mass_g  sex
0      3750.0  Male
1      3800.0  Female
2      3250.0  Female
3         NaN   NaN
4      3450.0  Female
```

Информация о данных:

```
<class 'pandas.core.frame.DataFrame'>
```

RangeIndex: 344 entries, 0 to 343

Data columns (total 7 columns):

#	Column	Non-Null Count	Dtype
0	species	344 non-null	object
1	island	344 non-null	object
2	bill_length_mm	342 non-null	float64
3	bill_depth_mm	342 non-null	float64
4	flipper_length_mm	342 non-null	float64
5	body_mass_g	342 non-null	float64
6	sex	333 non-null	object


dtypes: float64(4), object(3)

memory usage: 18.9+ KB

None

Размер после удаления пропусков: (333, 7)

Числовые признаки для pairplot: ['bill_length_mm', 'bill_depth_mm', 'flipper_length_mm', 'body_mass_g']



Задача №23.

Для набора данных для одного (произвольного) числового признака проведите обнаружение и удаление выбросов на основе правила трех сигм.

1. Импорт библиотек

```
import seaborn as sns
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

2. Загрузка данных (отличается от лекции)

```
df = sns.load_dataset('penguins')
df_clean = df.dropna().copy()
print("Исходный размер (без пропусков):", df_clean.shape)
```

3. Парные диаграммы ДО удаления выбросов

```
numerical_cols = df_clean.select_dtypes(include=[np.number]).columns.tolist()
print("Числовые признаки:", numerical_cols)

sns.pairplot(df_clean, vars=numerical_cols, hue='species', diag_kind='kde')
plt.suptitle('Парные диаграммы (до удаления выбросов)', y=1.02)
plt.show()
```

4. Выбор числового признака и удаление выбросов по 3σ

```
feature = 'body_mass_g' # можно заменить на любой числовой
data = df_clean[feature]

mean = data.mean()
std = data.std()
lower = mean - 3*std
upper = mean + 3*std

print(f"\nПризнак '{feature}':")
print(f" Среднее = {mean:.2f},  $\sigma$  = {std:.2f}")
print(f" Границы  $3\sigma$ : [{lower:.2f}, {upper:.2f}]")

outliers = data[(data < lower) | (data > upper)]
print(f" Количество выбросов: {len(outliers)}")
if len(outliers) > 0:
    print(f" Выбросы: {outliers.tolist()}")
else:
    print(" Выбросов не обнаружено (данные уже хорошо распределены)")

# Удаляем выбросы
df_filtered = df_clean[(df_clean[feature] >= lower) & (df_clean[feature] <= upper)]
print(f"\nРазмер после удаления выбросов: {df_filtered.shape}")
print(f"Удалено записей: {df_clean.shape[0] - df_filtered.shape[0]}")
```

5. Парные диаграммы ПОСЛЕ удаления выбросов

```
sns.pairplot(df_filtered, vars=numerical_cols, hue='species', diag_kind='kde')
plt.suptitle('Парные диаграммы (после удаления выбросов)', y=1.02)
plt.show()
```


6. Дополнительная проверка (сравнение распределения)

```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
axes[0].hist(df_clean[feature], bins=20, alpha=0.7, label='До удаления')
axes[0].axvline(lower, color='r', linestyle='--', label='Нижняя граница')
axes[0].axvline(upper, color='r', linestyle='--', label='Верхняя граница')
axes[0].set_title(f'{feature} (до)')
axes[0].legend()

axes[1].hist(df_filtered[feature], bins=20, alpha=0.7, color='green', label='После удаления')
axes[1].set_title(f'{feature} (после)')
axes[1].legend()
plt.tight_layout()
plt.show()
```

Исходный размер (без пропусков): (333, 7)
Числовые признаки: ['bill_length_mm', 'bill_depth_mm', 'flipper_length_mm', 'body_mass_g']

Парные диаграммы (до удаления выбросов)



Признак "body_mass_g":
 Среднее = 4287.86, σ = 885.22
 Границы 3 σ : [1791.41, 6622.78]
 Количество выбросов: 0
 Выбросов не обнаружено (данные уже хорошо распределены)

Размер после удаления выбросов: (333, 7)
 Удалено записей: 0

Парные диаграммы (после удаления выбросов)

